

Relatório Projeto Final Grupo 5 - Predição de Preço de Aluguel

1st Aline Manhães
2023100253

2nd Marcela Carpenter
2023100260

3rd Raony Togneri
2023102512

Abstract—No mercado imobiliário, a decisão de realizar a locação de um imóvel está bastante relacionada a fatores como localização, características do imóvel e condições do mercado. Diante desse cenário, este projeto apresenta o desenvolvimento de um modelo de Aprendizado de Máquina capaz de estimar valores de locação de imóveis (casas e apartamentos) na Grande Vitória. O estudo engloba a coleta de dados via web scraping, análise exploratória, engenharia de atributos avançada e a avaliação de algoritmos de regressão (com destaque para o XGBoost), visando criar uma ferramenta de apoio para avaliação precisa e precificação adequada de imóveis.

Index Terms—Aprendizado de Máquina, Setor Imobiliário, Precificação, Web Scraping, Regressão, XGBoost.

I. INTRODUÇÃO

No mercado/setor imobiliário, a decisão de realizar a locação de um imóvel está bastante relacionada a fatores como localização, características do imóvel, condições do mercado, entre outros, sendo o preço afetado diretamente pela correlação entre eles. Diante desse cenário, é interessante a existência de uma ferramenta que auxilie a análise, a estimativa e a avaliação precisa para evitar supervalorização ou subvalorização ao precificar o imóvel.

A partir desse entendimento, o grupo desenvolveu um modelo de Aprendizado de Máquina capaz de estimar valores de imóveis (de casas e apartamentos) localizados na Grande Vitória, a partir de dados coletados da web.

II. COLETA DE DADOS

Para a coleta dos dados de aluguel dos imóveis, os sites utilizados pelo grupo foram a OLX e o NetImóveis. Com esses sites, foi possível obter cerca de 3.500 dados após alguns descartes. Foram descartados imóveis sem preço, cidade, bairro, tipo do imóvel (se é casa ou apartamento) e com títulos que referenciavam anúncios que fugiam do escopo definido para aluguel de imóvel, como aluguel de diária, lotes e espaços para eventos. Os dados foram coletados de forma diferente em cada site, mas para ambos foi utilizada a ideia de Web Scraping:

- Na OLX, o scrap foi feito para coletar os dados baseados no json que vinha de uma tag do next;
- No NetImóveis, o scrap foi feito para coletar os dados baseados na tag 'article' do HTML.

Para ambos os sites, foi analisado o título do anúncio. O grupo aceitou o tradeoff que os imóveis são anunciados com as informações que possuem, sem informar o que não possuem. Pensando nisso, o imóvel com título contendo as palavras

'diária', 'temporada', 'temporadas', 'dividir', 'divisao', 'compartilhar', 'compartilhamento', 'evento', 'festa', 'casamento', 'hostel' foi ignorado por fugir do escopo definido para o projeto de prever casas e apartamentos. Por causa dessa decisão, diversos anúncios problemáticos foram eliminados, embora alguns poucos reais acabaram sendo removidos também.

Além disso, outro tratamento feito com o título foi para identificar possíveis detalhes dos imóveis, como a presença ou ausência de elevador, porteiro, área de lazer (como piscina, salão de festas, área de churrasco ou quadras), academia, varanda e mobília. Caso o título citasse algum desses detalhes anteriores, o algoritmo atribuiu 1 na respectiva coluna, indicando a presença do atributo no imóvel. Caso não houvesse referência a nenhum detalhamento, o algoritmo atribuiu 0 na respectiva coluna.

Ao final, o dataset do grupo ficou com os seguintes atributos lidos ou identificados:

- id: identificação única da amostra (imóvel);
- cidade: cidade onde o imóvel está localizado (ex: Vitória, Vila Velha);
- bairro: bairro onde o imóvel está localizado (ex: Praia do Canto, Jardim da Penha);
- tipo: tipo do imóvel, sendo 0 para "casa" e 1 para "apartamento";
- area: área total em m² do imóvel;
- quartos: número de quartos do imóvel;
- banheiros: número de banheiros do imóvel;
- vagas: número de vagas de garagem disponíveis;
- elevador: indica a presença de elevador no prédio (1 para sim, 0 para não);
- porteiro: indica a presença de portaria/porteiro (1 para sim, 0 para não);
- area_lazer: indica se o imóvel/condomínio possui área de lazer, equivalente a churrasqueira, salão de festas, piscina ou quadra (1 para sim, 0 para não);
- academia: indica se o imóvel/condomínio possui academia (1 para sim, 0 para não);
- varanda: indica se o imóvel/condomínio possui varanda (1 para sim, 0 para não);
- mobiliado: indica se o imóvel é alugado já mobiliado (1 para sim, 0 para não).

III. ANÁLISE EXPLORATÓRIA

À medida que os dados foram coletados, foi possível ter maior clareza de como os imóveis estavam distribuídos, o que

auxiliou na melhor modelagem o problema e no tratamento de outliers.




Fig. 1. Distribuição da frequência da área dos imóveis.




Fig. 2. Distribuição da frequência dos preços de aluguel.

Os dados obtidos, tanto para o preço, quanto para a área, mostram uma distribuição que representa parte da população da Grande Vitória: os anúncios se concentram em valores mais populares. Nota-se nas Fig. 1 e Fig. 2 que, após os 150 m², por exemplo, a distribuição da frequência da área decai bastante. O mesmo acontece para o preço, onde a população de amostras está fortemente concentrada entre os R\$ 800,00 a R\$ 6.000,00, aproximadamente.

Para que o modelo do grupo tivessem um desempenho melhor, as caudas da esquerda e da direita de área e preço foram cortadas com base no IQR (Intervalo Interquartil). Esse corte possibilitou que o modelo acertasse com mais precisão os imóveis com as distribuições mais frequentes no conjunto de dados obtido. Em contrapartida, o modelo tende a errar mais quando os valores estão fora da área delimitada pelas linhas verticais vermelha e verde exibidas nas Fig. 1 e Fig. 2.

Outro detalhe observado foi como a distribuição dos bairros é desproporcional: a concentração maior está nos bairros mais populosos da Grande Vitória, em específico, bairros de Vitória e Vila Velha, Serra e Cariacica. Nota-se que a Fig. 3 mostra apenas os primeiros 45 bairros com maior número de imóveis observados para facilitar a visualização. 219 bairros foram cortados da Fig. 3, pois a exibição não tornaria possível distinguir os bairros e a diferença de frequência entre eles tende a zero.




Fig. 3. Distribuição dos imóveis pelos 45 bairros mais frequentes.

IV. ENGENHARIA DE ATRIBUTOS

Os atributos escolhidos para modelagem do problema foram: cidade, bairro, tipo, área, quartos, banheiros, vagas, elevador, porteiro, área de lazer, academia, varanda, mobiliado. Eles foram selecionados visando obter mais informações referentes ao imóvel para ajudar no treinamento dos modelos de predição.

Os atributos textuais, sendo eles a cidade, bairro e tipo, foram inicialmente normalizados (letras minúsculas e remoção de acentos e espaços substituídos por travessão) e posteriormente convertidos para tipos numéricos com as seguintes técnicas:

- Cada cidade se torna uma coluna na tabela, a partir da técnica de *One Hot Encoding*. Essa técnica foi escolhida pois há apenas 7 cidades na Grande Vitória, o que gera 7 novas colunas e a remoção da coluna 'cidade'. Onde o anúncio for referente a determinada cidade, ele terá o valor 1 na coluna correspondente e 0 caso contrário. Essa etapa é realizada no arquivo *treino.py*;
- Os bairros são agrupados em um grupo único chamado 'Outro', caso possuam menos que 2 anúncios no total. Além disso, são codificados pelo *TargetEncoder*, que utiliza a média da variável alvo (preço do imóvel por m², nesse caso), e gera uma coluna 'bairro_codificado' contendo esse valor. Essas técnicas foram calculadas apenas no conjunto de treino e aplicadas no conjunto de teste, a fim de impedir vazamento de dados. Após essa aplicação, a coluna 'bairro' é removida. Essa etapa é realizada no arquivo *treino.py*;
- Os tipos dos imóveis são convertidos com base no tipo real do anúncio. Se for uma casa, a coluna tipo terá valor 0, caso contrário, terá valor 1. Essa etapa é realizada no arquivo *webscraper.py*.

Para os demais atributos numéricos, o tratamento foi um pouco diferente e todos foram realizados no arquivo *webscraper.py* após a coleta dos dados:

- Área, quarto e banheiro foram tratados eliminando textos, como unidade de medida ou algum tipo de especificação (por exemplo, "200m²" para "200", "5 ou mais quartos" para 5). Se o seu valor fosse vazio ou 0, esse dado era ignorado do conjunto de dados;

- Para as vagas, se o anúncio declarava a quantidade de vagas, então esse dado seria limpo e salvo. Caso contrário, isto é, se o anúncio não informava a quantidade de vagas no campo determinado, o valor preenchido era 0, assumindo que esse atributo não existe no imóvel;
- Quanto a elevador, porteiro, área de lazer, academia, varanda e mobiliado, estes atributos foram preenchidos com base nas tags disponíveis para isso ou no título do imóvel. Caso as palavras buscadas para determinar a existência desses atributos não fossem encontradas, eles eram preenchidos com valor 0. Se elas fossem encontradas, eles eram preenchidos com valor 1.

Uma vez que todos os atributos foram convertidos ao tipo numérico, foi aplicado o *StandardScaler* para padronizar seus valores em uma mesma escala, de forma que o modelo de predição não valorizasse um atributo mais que o outro por conta da unidade utilizada.

Já no arquivo *inferencia.py*, são recuperados, via *joblib*, o modelo preditivo, o scaler (utilizado pelo *StandardScaler*), o encoder (utilizado pelo *TargetEncoder*), o nome das colunas utilizadas no modelo e os imputadores de área, quartos e banheiros calculados no treinamento, para o caso de *entrada.csv* ter alguma 'área' vazia. Em seguida, são lidos os dados contidos no arquivo *entrada.csv*, conforme especificado pelo professor, que serão inferidos pelo modelo gerado pelo grupo. Para que isso seja possível, o grupo teve que tratar os dados lidos da seguinte maneira:

- É verificado se os dados lidos fazem parte do conjunto esperado de dados, por exemplo, se a cidade está na Grande Vitória, se 'porteiro' assume apenas valores 0 ou 1, entre outros. Caso o valor não se encontre no conjunto esperado, este é tratado como vazio;
- Se os atributos de 'vagas', 'elevador', 'porteiro', 'área_lazer', 'academia', 'varanda' e 'mobiliado' estiverem vazios, são preenchidos com 0. As demais colunas não são preenchidas caso estejam vazias, apenas são convertidas para NaN, que é uma maneira mais interessante de representar um valor vazio para o modelo preditivo;
- As colunas 'cidade' e 'bairro' são normalizadas, tornando as letras minúsculas e removendo acentos e espaços;
- As colunas 'área', 'quartos', 'banheiros' e 'vagas' foram tratadas eliminando textos e têm seu valor inteiro retornado;
- Se as colunas 'área', 'quartos' ou 'banheiros' estiverem vazias, é aplicada uma imputação calculada pela média dessas colunas nos bairros do conjunto de treinamento;
- A técnica de *One Hot Encoding* é aplicada na coluna 'cidade', o encoder é aplicado em 'bairro' e o scaler é aplicado em todos os atributos, da mesma maneira que foram no treinamento;
- Garante-se que todas as colunas usadas no treino existam, na mesma ordem, no conjunto de dados a ser inferido.

A partir daí, os dados estão prontos para serem inferidos.

V. MODELAGEM DO PROBLEMA

A etapa de treinamento inicia com a aplicação de algumas técnicas de pré-processamento em algumas colunas, como a limitação de outliers em área e preço, e o já citado *One Hot Encoding* na coluna de cidades. Em seguida, o loop principal implementa uma validação cruzada com estratificação dos dados em partes (folds) - através da discretização do y em categorias de preço -, de forma que a cada iteração, essas partes se revezam no papel de conjunto de treino e de teste, a fim de se ter métricas mais confiáveis sobre o desempenho do modelo e um uso mais eficiente da divisão dos dados. Em relação à estratificação, essa técnica foi escolhida devido à distribuição assimétrica dos imóveis ao longo da faixa de valores, evitando que todos os imóveis mais caros ficassem concentrados em uma única parte, caso elas fossem divididas de forma completamente aleatória, e mantendo uma proporção parecida de imóveis baratos, médios e caros em cada fold.

Ainda antes do treinamento, o código implementa a codificação dos bairros de valores categóricos para numéricos e faz um escalonamento com *StandardScaler* para padronizar os dados, e aplica uma transformação logarítmica em y para comprimir a escala de preços, cuja distribuição possui cauda longa para a direita, em uma escala em que modelo consegue aprender padrões de forma mais equilibrada. Depois de se testar os melhores parâmetros para o modelo a ser treinado, o treinamento ocorre efetivamente, as previsões são geradas e as métricas são calculadas e armazenadas para análise posterior do desempenho obtido.

O grupo escolheu avaliar alguns modelos de regressão para a resolução do problema. Foram eles: RandomForest, XGBoost, KNN e HistGradientBoosting. Esses modelos tiveram seu desempenho avaliado através da execução do *Randomized-SearchCV*, que, a partir de possíveis valores para os parâmetros dos modelos, escolhia os que obtinham melhor resultado e retornava o melhor modelo de predição gerado. Os parâmetros escolhidos para serem testados focaram em limitar os modelos em sua profundidade de análise e número de estimadores e em penalizar características que poderiam gerar overfitting. Nos testes do grupo, o modelo que desempenhou melhor resultado foi o XGBoost, que foi o modelo final escolhido. O XGBoost gerou um modelo que tem o grau de importância dado aos atributos detalhado na Fig. 4.

A análise que o grupo utilizou para avaliar os resultados foi a visualização do MAPE e dos erros R^2 para treino e teste, buscando um alto R^2 de teste, mas com uma diferença pequena para o R^2 do treino para não gerar overfitting, além de um MAPE pequeno, a fim de ter um modelo preciso.

VI. RESULTADOS

Em relação às métricas, foram utilizadas as seguintes: RMSE (Raiz do Erro Quadrático Médio), MAE (Erro Médio Absoluto), R^2 (R-quadrado) e MAPE (Erro Percentual Absoluto Médio), sendo as duas últimas escolhidas pelo grupo para análise mais profunda. O R^2 indica a proporção de variação dos preços que o modelo consegue explicar, enquanto o MAPE




Fig. 4. Grau de importância dos atributos gerado pelo modelo XGBoost.

indica a porcentagem de erro médio entre os valores previstos e os valores reais.

O grupo obteve aproximadamente 0.91 no treino e 0.78 no teste, indicando um possível overfitting, embora a diferença entre os valores ainda esteja abaixo de 0.15, valor estabelecido como limite máximo para essa diferença. Já o MAPE encontrado, de aproximadamente 21%, foi classificado como razoável para o problema, considerando a falta de dados com valores muito baixos e muito altos e que as amostras dentro dessas faixas puxaram a métrica para valores piores.

Nas Fig. 5, Fig. 6 e Fig. 7 podem ser observados alguns resultados obtidos para amostras em geral, amostras mais baratas e amostras mais caras, respectivamente.

@ Comparacao (real x previsto x diferenca)		
Real: R\$ 1300.00	Previsto: R\$ 6821.61	Diferença: 80.94%
Real: R\$ 1000.00	Previsto: R\$ 1626.06	Diferença: 38.50%
Real: R\$ 1000.00	Previsto: R\$ 1761.75	Diferença: 2.13%
Real: R\$ 900.00	Previsto: R\$ 1341.57	Diferença: 32.91%
Real: R\$ 1200.00	Previsto: R\$ 1566.28	Diferença: 23.39%
Real: R\$ 1800.00	Previsto: R\$ 2486.89	Diferença: 27.62%
Real: R\$ 4000.00	Previsto: R\$ 5853.60	Diferença: 20.85%
Real: R\$ 1000.00	Previsto: R\$ 1459.57	Diferença: 31.49%
Real: R\$ 1500.00	Previsto: R\$ 2384.25	Diferença: 37.09%
Real: R\$ 3200.00	Previsto: R\$ 3698.64	Diferença: 13.48%

Fig. 5. Resultados obtidos para amostras em geral.

@ Comparacao das amostras MAIS BARATAS		
Real: R\$ 700.00	Previsto: R\$ 812.53	Diferença: 13.85%
Real: R\$ 700.00	Previsto: R\$ 2183.23	Diferença: 67.94%
Real: R\$ 750.00	Previsto: R\$ 1184.67	Diferença: 36.69%
Real: R\$ 750.00	Previsto: R\$ 742.94	Diferença: 0.94%
Real: R\$ 780.00	Previsto: R\$ 794.18	Diferença: 1.79%
Real: R\$ 790.00	Previsto: R\$ 831.24	Diferença: 4.96%
Real: R\$ 795.00	Previsto: R\$ 2496.01	Diferença: 68.15%
Real: R\$ 800.00	Previsto: R\$ 856.83	Diferença: 6.63%
Real: R\$ 800.00	Previsto: R\$ 1718.96	Diferença: 53.46%
Real: R\$ 800.00	Previsto: R\$ 792.78	Diferença: 0.90%

Fig. 6. Resultados obtidos para amostras mais baratas.

@ Comparacao das amostras MAIS CARAS		
Real: R\$ 17000.00	Previsto: R\$ 8314.95	Diferença: 51.09%
Real: R\$ 17000.00	Previsto: R\$ 11999.99	Diferença: 29.41%
Real: R\$ 16000.00	Previsto: R\$ 15759.40	Diferença: 1.50%
Real: R\$ 16000.00	Previsto: R\$ 12240.77	Diferença: 23.50%
Real: R\$ 16000.00	Previsto: R\$ 8841.31	Diferença: 44.74%
Real: R\$ 16000.00	Previsto: R\$ 6472.78	Diferença: 59.55%
Real: R\$ 15000.00	Previsto: R\$ 13282.93	Diferença: 11.45%
Real: R\$ 15000.00	Previsto: R\$ 15535.95	Diferença: 3.45%
Real: R\$ 15000.00	Previsto: R\$ 8073.06	Diferença: 46.18%
Real: R\$ 15000.00	Previsto: R\$ 15713.86	Diferença: 4.54%

Fig. 7. Resultados obtidos para amostras mais caras.

VII. CONCLUSÃO

Com base nos resultados analisados, é possível concluir que o modelo obteve um desempenho razoável, sendo sua variância média de erro em 21%, tendo em vista a baixa quantidade de dados de imóveis nos valores menos frequentes, como abaixo de R\$ 800,00 e acima de R\$ 6.000,00.

Como citado anteriormente, o modelo que gerou as melhores métricas foi o XGBoost. Uma possível justificativa seria que, por treinar árvores de forma sequencial, corrigindo os erros das anteriores, ele também tende a ter melhor desempenho que ensembles mais simples, como RandomForest, além de ser naturalmente mais resistente a outliers residuais que sobram mesmo depois da limpeza dos dados.

Diante de tudo disso, algumas melhorias futuras foram pensadas pelo grupo de forma a possibilitar uma precisão ainda maior do modelo, sendo elas:

- Utilização de coordenadas geográficas dos imóveis;
- Inserção da distância do imóvel até locais de maior relevância (como shopping, praia e mercado);
- Melhor análise semântica dos anúncios nos campos de descrição.

Ainda assim, os resultados obtidos demonstram que é possível prever de maneira razoável o valor de aluguel de imóveis na Grande Vitória a partir dos dados de anúncios, reforçando o potencial desse tipo de ferramenta de apoio na avaliação de preços do mercado imobiliário.